

# Model-Free Episodic Control & Neural Episodic Control

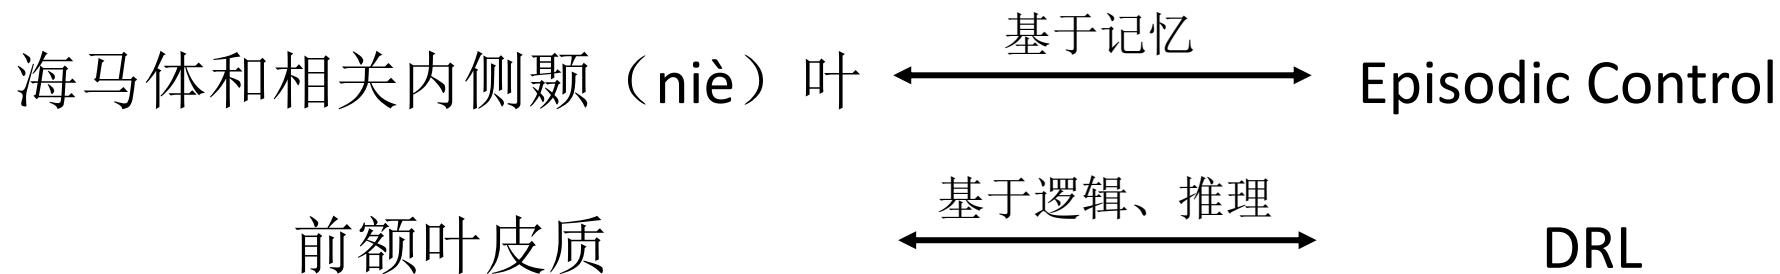
presented by Jason TOKO

# 背景与动机

- DRL学习速度较慢：
  - 1.SGD优化一般需要较小的学习率；
  - 2.环境的奖励反馈稀疏；
  - 3.经验回放和目标网络使得奖励信息反向传播更慢。
- Episodic Control: 一种memory-based的方法，利用已有的经验快速查找能产生高回报的动作。

# 背景与动机

- 大脑的学习机制：



- 在不同场景，大脑学习、记忆和决策机制都有所不同。

# Model-Free Episodic Control

- Model-Free Episodic Control建造了Q值表格来存储和回放经验
- 存储（更新）：

$$Q^{\text{EC}}(s_t, a_t) \leftarrow \begin{cases} R_t & \text{if } (s_t, a_t) \notin Q^{\text{EC}}, \\ \max \{ Q^{\text{EC}}(s_t, a_t), R_t \} & \text{otherwise,} \end{cases}$$

- 回放（估计）：

$$\widehat{Q^{\text{EC}}}(s, a) = \begin{cases} \frac{1}{k} \sum_{i=1}^k Q^{\text{EC}}(s^{(i)}, a) & \text{if } (s, a) \notin Q^{\text{EC}}, \\ Q^{\text{EC}}(s, a) & \text{otherwise,} \end{cases}$$

# Model-Free Episodic Control

- 算法:

---

**Algorithm 1** Model-Free Episodic Control.


---

```
1: for each episode do
2:   for  $t = 1, 2, 3, \dots, T$  do
3:     Receive observation  $o_t$  from environment.
4:     Let  $s_t = \phi(o_t)$ .
5:     Estimate return for each action  $a$  via  $\widehat{Q}^{\text{EC}}(s, a) = \begin{cases} \frac{1}{k} \sum_{i=1}^k Q^{\text{EC}}(s^{(i)}, a) & \text{if } (s, a) \notin Q^{\text{EC}}, \\ Q^{\text{EC}}(s, a) & \text{otherwise,} \end{cases}$ 
6:     Let  $a_t = \arg \max_a \widehat{Q}^{\text{EC}}(s_t, a)$ 
7:     Take action  $a_t$ , receive reward  $r_{t+1}$ 
8:   end for
9:   for  $t = T, T - 1, \dots, 1$  do
10:    Update  $Q^{\text{EC}}(s_t, a_t)$  using  $R_t$  according to  $Q^{\text{EC}}(s_t, a_t) \leftarrow \begin{cases} R_t & \text{if } (s_t, a_t) \notin Q^{\text{EC}}, \\ \max \{Q^{\text{EC}}(s_t, a_t), R_t\} & \text{otherwise,} \end{cases}$ 
11:   end for
12: end for
```

---

# Neural Episodic Control

- Agent由三个部分组成：
  - 卷积网络：输入 $s$ ，输出 $h$
  - 可微神经字典(Differentiable Neural Dictionary, DND):输入 $h$ 、 $a$ ，输出 $w$
  - 输出网络：输入 $w$ ，输出 $Q(s,a)$
- 结构图



# Neural Episodic Control

- DND组成：每一个动作 $a \in \mathcal{A}$ 各对应一个记忆模块 $M_a = (K_a, V_a)$   
 $K_a$ 为关键字 $h_i$ 的集合， $V_a$ 为值 $v_i$ 的集合

- DND查找

- 1、通过 $k(x, y)$ 计算关键字 $h$ 与字典关键字 $h_i$ 的kernel值，计算权值

$$w_i = k(h, h_i) / \sum_j k(h, h_j),$$

- 2、加权求和

$$o = \sum_i w_i v_i,$$

# Neural Episodic Control

- DND更新

- 使用N-step Q-value作为DND更新目标

$$Q^{(N)}(s_t, a) = \sum_{j=0}^{N-1} \gamma^j r_{t+j} + \gamma^N \max_{a'} Q(s_{t+N}, a')$$


- 若关键字h不存在于字典，则直接加入DND；
    - 若关键字h已存在于字典，则使用Q-learning方法更新：

$$Q_i \leftarrow Q_i + \alpha(Q^{(N)}(s, a) - Q_i)$$



# Neural Episodic Control

- DND查找与更新



# Neural Episodic Control

- 整个Agent训练:
  - 从replay buffer中随机采样minibatch( $s_t, a_t, R_t$ ) 。其中  $R_t = Q^N(s_t, a_t)$
  - 损失函数:

$$L = \frac{1}{M} \sum_{(s_t, a_t, R_t)} [R_t - Q(s_t, a_t)]^2$$

# Neural Episodic Control

- 算法: 

---

**Algorithm 1** Neural Episodic Control

---

$\mathcal{D}$ : replay memory.

$M_a$ : a DND for each action  $a$ .

$N$ : horizon for  $N$ -step  $Q$  estimate.

**for** each episode **do**

**for**  $t = 1, 2, \dots, T$  **do**

    Receive observation  $s_t$  from environment with embedding  $h$ .

    Estimate  $Q(s_t, a)$  for each action  $a$  via (1) from  $M_a$

$a_t \leftarrow \epsilon$ -greedy policy based on  $Q(s_t, a)$

    Take action  $a_t$ , receive reward  $r_{t+1}$

    Append  $(h, Q^{(N)}(s_t, a_t))$  to  $M_{a_t}$ .

    Append  $(s_t, a_t, Q^{(N)}(s_t, a_t))$  to  $\mathcal{D}$ .

至少N步以后才能加入

    Train on a random minibatch from  $\mathcal{D}$ .

**end for**






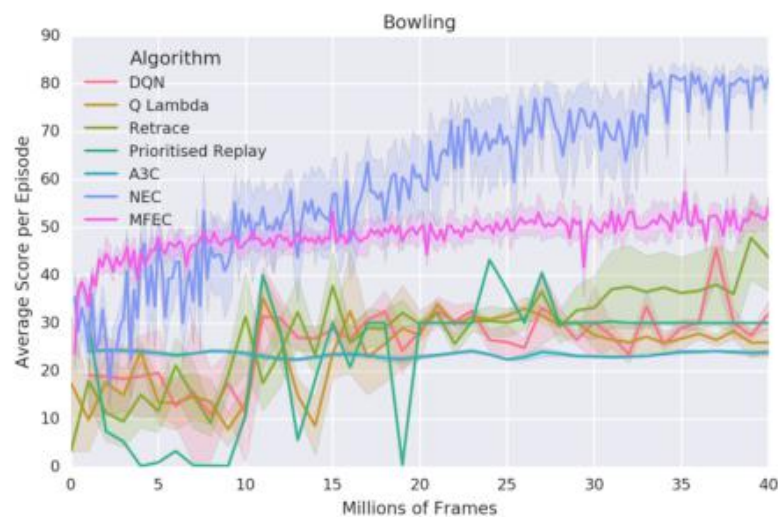
**end for**

---

# More.....

- Model-Free Episodic Control和Neural Episodic Control皆使用了字典来实现Q值查找和更新，考虑内存限制以及效率，有以下措施：
  - 1、限制表格大小，溢出时替换最近访问次数最少的状态；
  - 2、使用K-邻近状态来更新而非整个字典，并使用KD树实现查找

# 实验



# Episodic Control与DRL对比

- 优点：解决DRL存在的三个问题，通过不断存储和再现经验，实现快速学习。
- 缺点：Episodic Control 通用性较差，更适用于在exploitation比exploration重要且相对来说噪音比较少的环境。